

基于多尺度分解和深度学习的锂电池寿命预测

胡天中, 余建波

(同济大学 机械与能源工程学院, 上海 201804)

摘要: 针对目前的剩余寿命预测 (RUL) 方法存在模型适应性差及预测不准确等问题, 提出多尺度深度神经网络的锂电池健康退化预测模型. 通过经验模态分解 (EMD) 方法和相关性分析 (CA), 将采集到的锂电池能量数据分解为主趋势数据和波动数据; 采用深度置信网络 (DBN) 和长短期记忆网络 (LSTM), 分别对主趋势与波动数据进行建模; 将 DBN 与 LSTM 预测结果进行有效集成, 得到锂电池的健康预测结果. 实验结果表明, 利用该方法能够有效地对锂电池的健康趋势进行拟合, 得到准确的 RUL 预测结果, 性能优于其他典型的预测方法.

关键词: 锂电池; 剩余寿命预测 (RUL); 多尺度分析; 深度置信网络; 长短期记忆网络 (LSTM)

中图分类号: TH 165; TN 911 **文献标志码:** A **文章编号:** 1008-973X(2019)10-0001-13

Life prediction of lithium-ion batteries based on multiscale decomposition and deep learning

HU Tian-zhong, YU Jian-bo

(School of Mechanical Engineering, Tongji University, Shanghai 201804, China)

Abstract: A health degradation prediction model of lithium batteries based on multi-scale deep neural network was proposed aiming at the problems of poor model adaptability and inaccurate prediction in current remaining useful life (RUL) prediction methods. The collected energy data of lithium-ion batteries were decomposed into main trend data and fluctuation data by ensemble empirical mode decomposition (EMD) and correlation analysis (CA). Then deep belief network (DBN) and long short-term memory (LSTM) were used to model the main trend and fluctuation data respectively. The predicting outcomes of DBN and LSTM were effectively integrated to obtain the health predicted results of lithium-ion battery. The experimental results show that the method can effectively fit the health trend of lithium-ion batteries and obtain accurate RUL prediction results. The performance of the method is better than other typical prediction methods.

Key words: lithium-ion battery; remaining useful life (RUL); multiscale analysis; deep belief network; long short-term memory (LSTM)

预诊健康管理系统作为一种先进的维护技术, 目的是提高设备的可靠性和经济效益^[1-3]. 锂电池作为许多系统的核心部件^[4-5], 其健康状况和性能影响整个设备的运作. 预测锂电池未来的健康状况, 对于提高该类系统的可靠性具有重要意义.

影响电池健康状态 (state of health, SOH) 的因素包括温度、放电深度和充电速率等, 但这些指标不能直接表征电池的性能退化程度, 对于在线检测存在一定困难^[6]. 电池实际容量是指电池在充满电的情况下所储存的电能, 是能够直接表征

收稿日期: 2019-05-13. 网址: www.zjujournals.com/eng/article/2019/1008-973X/201910000.shtml

基金项目: 国家自然科学基金资助项目 (51375290, 71777173); 中央高校基本科研业务费资助项目; 上海科委创新科技行动计划资助项目 (17511109204).

作者简介: 胡天中 (1995—), 男, 硕士生, 从事深度学习与信号处理的研究. orcid.org/0000-0003-3705-7433. E-mail: 305122638@qq.com
通信联系人: 余建波, 男, 教授. orcid.org/0000-0003-3204-2486. E-mail: jbyu@tongji.edu.cn

电池寿命退化的重要参数,因此在电池剩余寿命 (remaining useful life, RUL) 预测研究中常被作为健康指标,描述电池健康状况的退化程度^[7-8]。

现有的锂电池 RUL 预测方法可以分为失效物理模型和数据驱动模型。失效物理模型是通过建立数学模型来表示锂电池性能退化的过程^[9-12],然而该方法易受到噪声和环境的干扰,难以对电池的健康状况进行动态检测,鲁棒性及适应性较差。数据驱动方法由于灵活性高、易实现等优点,是目前电池寿命预测的主流方法^[13-20]。该类算法从电池的性能退化数据中提取出寿命特征参数,通过建模输出预测结果,为系统维护提供决策信息。电池容量的退化过程中会出现局部重生现象^[2],这种现象所产生的波动性会严重影响预测算法的性能,在实际情况中很难进行有效预测。

针对上述问题, Xing 等^[21-23]提出融合或集成模型驱动与数据驱动的预测方法,充分发挥不同方法的优点,以获得更佳的性能。 Dong 等^[24]提出基于支持向量回归 (support vector regression, SVR) 和粒子滤波 (particle filter, PF) 的预测方法。 Yu^[25]在结合逻辑回归 (logic regression, LR) 和高斯过程回归 (Gaussian process regression, GPR) 的基础上,提出解决锂电池 SOH 估计和 RUL 预测的多尺度方法。上述基于融合技术的预测方法研究有效提高了 RUL 预测的准确度,但目前这类方法存在一些问题: 1) 融合多种方法使模型的参数更复杂,导致模型计算量大,预测不稳定; 2) 大多数融合方法依赖大规模的数据集进行训练,泛化性较差; 3) 传统的机器学习方法本身的局限性影响融合方法的优化效果。

深度学习在图像处理、语音识别等领域取得了巨大成功^[26-28],虽然目前深度学习多数情况都是用于解决分类问题^[29-31],但是由于其在特征提取方面的优异性能,在故障诊断和预测领域开始受到关注。陶洁等^[32]基于 Teager 能量算子构建深度置信网络 (deep belief network, DBN) 模型,对不同损伤程度的滚动轴承进行故障诊断。 Ma 等^[33]提出基于长短期记忆网络 (long short-term memory, LSTM) 的预测模型,对交通流速状况进行在线监控。 Kuremoto 等^[34]利用 DBN 对金融时间序列进行预测,通过粒子群算法对网络的大小和学习速度进行优化。针对设备 RUL 预测问题, LSTM^[35]与 DBN^[36]等深度学习方法的有效性得到了验证。现在大多数基于深度学习的预测方法仅涉及一个

单一的模型,在对不同对象进行预测时,很难一直保持良好的性能。此外,深度学习在锂电池 RUL 预测上的应用较少,电池退化过程中的局部重生现象限制了单一模型的预测能力。

本文提出基于多尺度分解和深度神经网络的电池 RUL 预测模型,在现今研究的基础上实现了进一步的创新: 1) 首先通过集合经验模态分解 (ensemble empirical mode decomposition, EEMD) 与相关性分析 (correlation analysis, CA) 对时间序列进行多尺度分解,将电池健康指标中的局部特征和全局退化趋势进行自适应分离,解决了电池能量指标重生引起的剧烈波动问题; 2) 考虑到深度神经网络具有优异的预测性能,将多组分解数据分别用于构建 DBN 模型和 LSTM 模型,最后将 2 个预测模型的结果进行集成得到可靠的锂电池寿命预测结果,弥补了单一模型预测稳定性较差的缺陷。

1 基于多尺度分解和深度神经网络的集成预测方法

由于电池容量数据易于采集且能够直接反映电池的健康状况,将电池容量作为 SOH 指标描述电池的退化趋势。算法的整体框架如图 1 所示,首先通过 EEMD 和 CA 将数据分解成主趋势和波动数据,对 2 类数据分别进行分析,避免了电池退化过程中出现重生现象对预测所带来的不良影响; 基于深度神经网络在特征提取和时间序列分析方面的优异性能,采用 DBN 和 LSTM 对 2 类数据分别进行建模,将各组模型的输出进行有效集成,得到最终的组合预测结果。

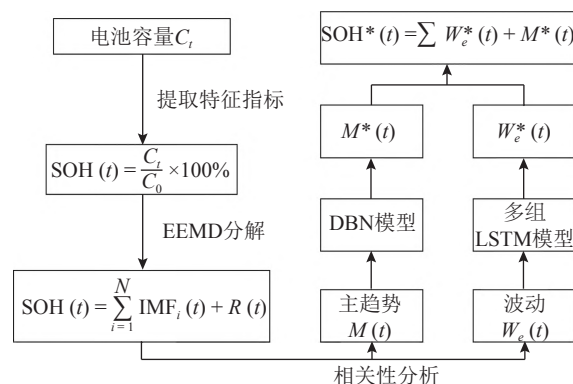


图 1 基于多尺度分解和深度学习的锂电池寿命预测方法

Fig.1 Life prediction of lithium batteries based on multiscale decomposition and deep learning

1.1 SOH 指标

锂电池在使用过程中,随着充、放电周期的增加,SOH 一般呈现下降趋势.电池容量作为 SOH 的重要指标,当容量衰退到一定程度时,电池将无法继续正常工作,达到寿命终点.采用锂电池的容量来表征 SOH, 定义为

$$\text{SOH}(t) = \frac{C_t}{C_0} \times 100\%. \quad (1)$$

式中: C_t 为锂电池在第 t 个充放电周期的容量, C_0 为该锂电池的初始容量.当锂电池容量下降至失效阈值(failure threshold, FT)时,可以认为该锂电池达到寿命终点(end of life, EoL),当前容量到失效阈值之间所对应的间隔周期为电池的 RUL.

1.2 基于 EEMD 与 CA 的多尺度分解

经验模态分解(empirical mode decomposition, EMD)^[37-38]是对非平稳信号进行分析的方法,它将信号分解为本征模态函数(intrinsic mode function, IMF)和余量(remainder),自适应地表示信号中的局部特征和全局退化趋势.EMD 在分解时容易产生模态混叠现象,导致错误的 IMF 分量出现,从而使 IMF 丧失具体的物理意义.EEMD^[39]是针对 EMD 方法的不足所提出的噪声辅助数据分析方法.EEMD 的原理是进行 n 次重复 EMD 分解信号的过程,在每次分解过程中都向原始信号加入零均值、固定方差的白噪声,有效地解决了模态混叠现象.采用 EEMD 提取出锂电池 SOH 数据中的局部特征,大幅度降低了重生现象产生的数据波动对算法的预测性能所造成的影响.

针对收集到的锂电池 SOH 数据 $\text{SOH}(t)$, EEMD 分解的结果为

$$\text{SOH}(t) = \sum_{i=1}^N \text{IMF}_i(t) + R(t). \quad (2)$$

式中: N 为分解的 IMF 数量, $\text{IMF}_i(t)$ 为第 i 个分量, $R(t)$ 为余量.

考虑到数据分组较多可能导致最终的累计误差较大,使预测模型的精度下降.通过计算 $\text{SOH}(t)$ 和 $\text{IMF}_i(t)$ 之间的相关性系数,寻找出与原信号具有强相关性的若干组 IMF 分量.以实现对不同数据都具有良好的泛化性为目标,设定关联阈值 $\text{CT} = \max(\text{IMF}_i)/N$,用于选取相关系数 $r_k > \text{CT}$ 的 $\text{IMF}_k(t)$,将具有强相关性的 K 组 $\text{IMF}_k(t)$ 与余量 $R(t)$ 组合成为主趋势数据 $M(t)$,进行汇集预测:

$$M(t) = \sum_{k=1}^K \text{IMF}_k(t) + R(t). \quad (3)$$

其余分量 $\text{IMF}_{r^*}(t)$ 对于 $\forall r^*, r_{r^*} \leq \text{CT}$,假设剩余分量组数为 E ,将这些分量视为波动数据 $W_e(t)$,即该组电池容量数据中的第 e 组波动.

采用 EEMD 和 CA,将 SOH 时间序列中的全局退化趋势和局部特征有效分离,使得局部重生现象能够得到明显的改善,提高了 SOH 预测模型的预测性能.此外,自适应地设定关联阈值,能够进一步提高预测方法的鲁棒性.通过筛选方式,将具有强相关性的 IMF 数据与余量进行组合,在保留了局部特征的同时,避免了分组较多、造成累计误差过大的问题.

1.3 基于 DBN 的预测模型

DBN 是一个概率生成模型,由多个限制玻尔兹曼机(restricted Boltzmann machine, RBM)堆叠以及一个回归层(或分类层)组合而成的深度网络^[36].在 RBM 系统中,可视层节点 v_i 和隐含层节点 h_j 的总体能量函数定为

$$E(\mathbf{v}, \mathbf{h}) = - \sum_{i=1}^m v_i c_i - \sum_{j=1}^n h_j b_j - \sum_{i=1}^m \sum_{j=1}^n v_i h_j w_{ij}. \quad (4)$$

式中: m 和 n 分别为可视层和隐含层的节点数目; w_{ij} 为连接权值, c 为可视层的偏置项, b 为隐含层的偏置项; b 、 c 、 w 构成模型的参数集 θ .基于概率模型得到的概率分布如下:

$$P(\mathbf{v}, \mathbf{h}; \theta) = \frac{1}{Z(\theta)} \exp(-E(\mathbf{v}, \mathbf{h}; \theta)). \quad (5)$$

$$Z(\theta) = \sum_{\mathbf{v}, \mathbf{h}} \exp(-E(\mathbf{v}, \mathbf{h}; \theta)). \quad (6)$$

式中: $Z(\theta)$ 为配分函数.由于 DBN 层内无连接,隐节点 h_j 和显节点 v_i 被激活的概率可以通过下式计算:

$$P(h_j | \mathbf{v}) = \sigma \left(b_j + \sum_{i=1}^m w_{i,j} v_i \right), \quad (7)$$

$$P(v_i | \mathbf{h}) = \sigma \left(c_i + \sum_{j=1}^n w_{i,j} h_j \right). \quad (8)$$

为了得到模型的最优解,应用极大似然法确定 RBM 中的参数集 θ ,通过损失函数对参数集 θ 的偏导数进行参数值的更新^[32].在 DBN 训练完成后,利用模型参数将底层输入层显节点映射到顶层,得到输出结果 y :

$$y = f(\mathbf{v}; \theta). \quad (9)$$

以电池容量作为健康指标,经 EEMD 分解分离出的全局退化过程会随着时间呈现出逐步下降的趋势.由于 DBN 可以通过时间序列构建深层模型,通过历史数据找寻电池退化过程中的隐含规律,自适应地拟合下降趋势,从而能够实现高效的预测.采用 DBN 预测锂电池的主退化趋势,将时刻 $t-d+1, \dots, t$ 作为输入,其中 d 为输入时间窗大小,利用下式将训练好的模型进行 h 步提前健康预测:

$$M^*(t+h) = \text{DBN}(t-d+1, \dots, t). \quad (10)$$

DBN 模型的训练过程如图 2 所示,通过计算和重构各节点权值完成每层 RBM 的训练.在训练过程中,节点的样本统计概率与模型生成概率应尽量相等,从而使 DBN 模型能够实现更准确的预测.整个 DBN 的训练过程包含 2 个阶段:预训练阶段,利用无监督贪婪机制自底向上地进行逐层训练,将低层特征向高层特征转化,最终送入至顶层的回归层;反向微调阶段,自顶而下地微调网络权值,以达到降低误差的目的.

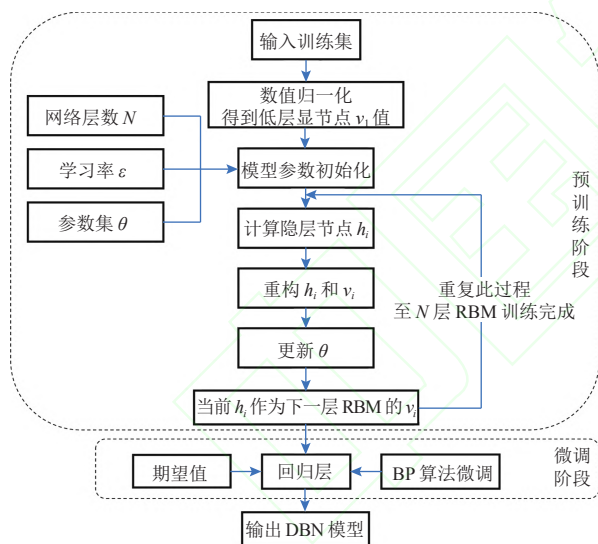


图 2 深度置信网络的训练流程

Fig.2 Flow chart of training deep belief network

1.4 基于 LSTM 的预测模型

LSTM 是一种特殊的循环神经网络 (recurrent neural network, RNN). 与传统的 RNN 相比, LSTM 在隐层增加了一个细胞状态 c , 对 RNN 的隐层进行改进, 解决了 RNN 在处理长序列数据时容易陷入梯度消失或梯度爆炸问题, 具有更有效的长期预测能力^[35].

LSTM 的核心由 input、forget 与 output 3 个“门 (gate)”组成, 网络结构可以有效遗忘之前的无用

信息, 保存有效的输入信息, 决定所需要输出的信息, 从而更加高效地处理长时间序列. 如图 3 所示为 LSTM 模型结构, 运算公式如下所示.

$$i_t = \sigma(W_i \cdot [y_{t-1}, x_t] + b_i), \quad (11)$$

$$f_t = \sigma(W_f \cdot [y_{t-1}, x_t] + b_f), \quad (12)$$

$$o_t = \sigma(W_o \cdot [y_{t-1}, x_t] + b_o), \quad (13)$$

$$\tilde{C}_t = \tanh(W_C \cdot [y_{t-1}, x_t] + b_C), \quad (14)$$

$$C_t = f_t \times C_{t-1} + i_t \times \tilde{C}_t, \quad (15)$$

$$y_t = o_t \tanh(C_t). \quad (16)$$

式中: x 表示输入向量, y 表示输出向量, i 、 f 、 o 、 C 分别表示输入门、遗忘门、输出门和细胞状态, 矩阵 W 和 b 分别为待训练的权重参数和偏置项, $\sigma(\cdot)$ 为 sigmoid 非线性函数.

按照式 (11)~(16) 计算模型的输出值, 根据定义的误差函数即式 (17)、(18) 反向计算每个 LSTM 细胞的误差项 S 和权重梯度, 从而更新网络参数:

$$S = (y_t - y_t^*)^2. \quad (17)$$

$$\text{loss} = -\frac{1}{N} \sum_{t=1}^N \ln S. \quad (18)$$

式中: N 为样本个数, y_t 为预测值, y_t^* 为真实值.

LSTM 引入记忆门单元和门限限制, 实现了对长距离信息的有效利用, 面对变化幅度较大的数据时能够及时地给予响应. 通过多门协作的方式, 使得 LSTM 具有良好的鲁棒性, 从而能够有效地应对梯度消失和梯度爆炸的问题. 基于 LSTM 在执行长期的时间序列预测上具有显著优势, 将 LSTM 模型用于预测电池容量退化过程中重生现




图 3 长短期记忆网络结构

Fig.3 Network structure of long short-term memory

象所产生的波动,以 $t-d+1,\cdots,t$ 时刻所对应的实际数据 $\mathbf{W}_{t-d+1}^*,\cdots,\mathbf{W}_t^*$ 作为输入,利用下式进行 h 步提前预测:

$$\mathbf{W}^*(t+h)=\text{LSTM}(\mathbf{W}_{t-d+1}^*,\cdots,\mathbf{W}_t^*). \tag{19}$$

LSTM 模型的训练过程如图 4 所示,在训练过程中,按照时间窗 d 的大小,从训练集中取出所需数据代入 LSTM 计算,得到输出值.通过损失函数计算损失值和权重梯度,优化网络参数.重复以上的计算和更新步骤,直至所有训练数据完成.

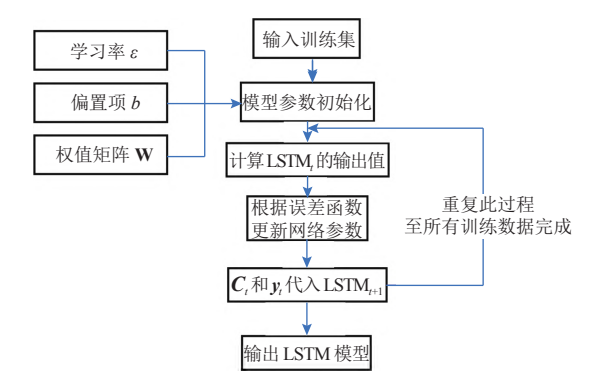


图 4 长短期记忆网络的训练流程

Fig.4 Flow chart of training long short-term memory network

1.5 组合模型预测框架

提出的预测模型的流程包括数据预处理、网络训练、模型预测 3 个模块.集成模型预测的具体步骤如下.

- 1)将收集到的电池容量时间序列数据 C_t 作为健康指标 SOH,利用式(1)得到 $\text{SOH}(t)$.
- 2)根据式(2)对 $\text{SOH}(t)$ 进行 EEMD 分解,得到若干组分量 $\text{IMF}_i(t)$ 和余量 $R(t)$.
- 3)对分量进行相关性分析,利用式(3)将相关性强的分量与余量进行累加,作为指标值的主趋势 $M(t)$,剩余分量 $\text{IMF}_i^*(t)$ 视为数据波动 $W_e(t)$.
- 4)将 $M(t)$ 和若干组 $W_e(t)$ 统一划分为训练集和数据集,并分别代入 DBN 和 LSTM 模型进行训练与预测.

5)通过式(4)~(9)、(11)~(18)对 DBN 模型和 LSTM 模型进行训练,将训练好的模型根据式(10)、(19)得到 DBN 模型的输出结果 $M^*(t)$ 以及多组 LSTM 模型的输出结果 $W_e^*(t)$,利用式(20)进行集成:

$$\text{SOH}^*(t)=\sum_{e=1}^E W_e^*(t)+M^*(t). \tag{20}$$

$\text{SOH}^*(t)$ 为提出方法的预测结果.

2 实验结果分析

根据 NASA PCoE 研究中心在爱达荷州国家实验室 (Idaho National Lab) 测试的 NASA 锂电池数据,对提出的预测模型的有效性进行评估^[40].采用额定容量为 2 A·h 的 18650 市售锂电池分为多组开展实验,在室温下通过 3 种不同的工作曲线 (充电、放电和阻抗) 进行试验.表 1 给出各项实验参数,即环境温度 (AT)、充电电流 (CC)、放电电流 (DC)、放电结束电压 (EOC) 和寿命结束标准 (EOLC).

表 1 用于预测实验的锂电池参数

Tab.1 Lithium battery parameters for prediction experiments

电池编号	AT/°C	CC/A	DC/A	EOC/V	EOLC/%
#5	24	1.5	2	2.7	30
#6	24	1.5	2	2.5	30
#7	24	1.5	2	2.2	30
#18	24	1.5	2	2.5	30

重复的充放电循环是电池加速衰落的主要原因, NASA PCoE 电池实验以电池容量退化至额定容量的 70% 作为电池寿命结束;参考该标准,将失效阈值设置为 1.38 A·h.各电池的容量变化曲线如图 5 所示.图中, T 为充放电周期, C 为电池容量.可知,锂离子电池的容量随着充放电次数的增加而减少.

2.1 SOH 时间序列的多尺度分解

以#5 电池为例演示算法流程,利用式(1)得到电池的 SOH 序列,如图 6(a)所示;应用 EEMD,将 SOH 时间序列分解为若干个分量 IMFs 和余量,分别如图 6(b)~(h)所示.利用 CA 方法提取出与总趋势有强相关性的分量 IMFs,将这些




图 5 电池容量的变化曲线

Fig.5 Variation curve of battery capacity

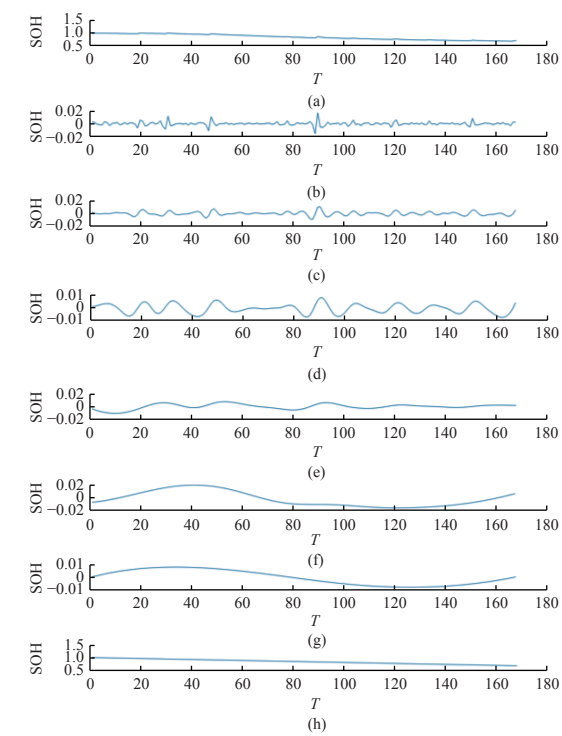


图 6 基于集合经验模态分解的健康状态时间序列

Fig.6 State of health time series based on ensemble empirical modal decomposition

表 2 本征模态函数的相关系数

Tab.2 Correlation coefficients of intrinsic mode functions

IMFs	数值	IMFs	数值
b	0.042	e	0.152
c	0.107	f	0.691
d	0.150	g	0.878




图 7 相关性分析的筛选结果

Fig.7 Filtering results of correlation analysis

IMFs 与余量进行组合, 分析结果如表 2、图 7 所示, 通过计算得到关联阈值 CT 为 0.146.

通过基于 EEMD 和 CA 的多尺度分解方法, 从数据中有效地提取出了局部特征, 即图 6(b)~(d) 的 3 组 IMF. 通过自适应筛选, 将没有明显波动的 3 组 IMF, 即图 6(e)~(g) 与余量累加构成图 7(h) 表示的主退化数据. 主退化数据呈现出很好的单调下降趋势, 不再受重生现象的影响. 通过上述方法对数据进行多尺度分解, 能够有效地将电池容量退化数据中的局部特征和全局退化趋势进行分离, 避免了重生现象对预测方法造成的不良影响, 这将有助于提高后续预测模型的性能.

2.2 One-step-ahead 预测

通过 One-step prediction 验证方法性能, 利用已知的数据预测出下一时刻的 SOH. 如表 3、4 所示分别为 DBN 和 LSTM 模型的网络参数设置. 以电池#5 为例, 共有 168 组数据, 取前 80 组作为训练集, 后 88 组作为测试集. 将训练集代入设置好的 LSTM 与 DBN 模型进行训练. 将训练好的模型对测试集进行预测, 集成各模型输出得到最终的预测结果, 各模型的输出与预测结果如图 8、9 所示.

从图 9 可以看出, DBN 的预测结果与实际容量的下降趋势基本保持一致, 同时 LSTM 模型为波动数据给予了及时的响应, 从而使得集成预测模型的输出值与实际值实现了高度拟合, 体现出了该方法的高效性能. 提出方法的运行时间如表 5 所示, 在实际情况中, 该方法所需的时间成本完全在可接受范围内, 且无需大量的历史数据训练模型, 因此能够用于电池 RUL 的在线预测, 实现对电池健康状况的动态监控, 从而能够在电池接近寿命终点前及时地更换, 保证系统能够持续地正常运行.

环境温度影响电池状态, 是实际情况中检验

表 3 深度置信网络的参数设置

Tab.3 Parameter setting of deep belief network

输入数	输出数	迭代次数	学习率	网络结构
3	1	100	0.001	3-35-25-15-1

表 4 长短期记忆网络的参数设置

Tab.4 Parameter setting of long short-term memory network

输入数	输出数	细胞数	学习率	迭代次数
8	1	20	0.01	3 000




图 8 各个模型的预测结果

Fig.8 Prediction results of models




图 9 集成预测结果

Fig.9 Integrated prediction results

表 5 预测算法的运行时间

Tab.5 Running time of prediction algorithm					s
多尺度分解	DBN训练	DBN预测	LSTM训练	LSTM预测	
3.19	10.41	0.28	1.66	1.08	

预测方法性能的重要因素. 为了验证本文预测方法在应对不同温度下的锂电池数据时具有良好的稳定性, 将该方法应用于一组 NASA 提供的锂电池 (No.32) 数据, 在 43℃ 的高温环境下进行试验, 表 6 给出实验参数. 该电池有 40 个数据点, 取前 20 组作为模型的训练集, 后 20 组作为测试集, 如图 10 所示为预测模型的输出. 针对高温环境下的锂电池数据, 该方法给出了有效的预测结果, 在预测阶段准确地对实际数据进行拟合, 同时在局部重生现象处实现了快速响应. 利用该实验证明了提出的集成预测方法能够处理不同温度的锂电池数据, 体现了良好的适应能力和实际应用价值.

表 6 用于高温预测实验的锂电池参数

Tab.6 Lithium battery parameters for high temperature prediction experiments

电池编号	AT/℃	CC/A	DC/A	EOC/V	EOLC/%
#32	43	1.5	4	2.7	30




图 10 高温环境下的预测结果

Fig.10 Prediction results of high temperature environment

为了更直观地体现出提出的集成模型性能, 分别对#5、#6、#7 和#18 电池进行多组对比实验, 其中 M1 为本文方法的结果, M2 为 EEMD 与 DBN 组合结果, M3 为 EEMD 与 LSTM 组合结果, M4 和 M5 分别为 DBN 与 LSTM 的结果. 通过下式计算 RMSE、MAPE 和 MAE 3 个指标来评估各种方法的性能:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (SOH_i - SOH_i^*)^2}, \tag{21}$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{SOH_i - SOH_i^*}{SOH_i} \right|, \tag{22}$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |SOH_i - SOH_i^*|. \tag{23}$$

式中: SOH_i^* 为预测值, SOH_i 为实际值, n 为时间序

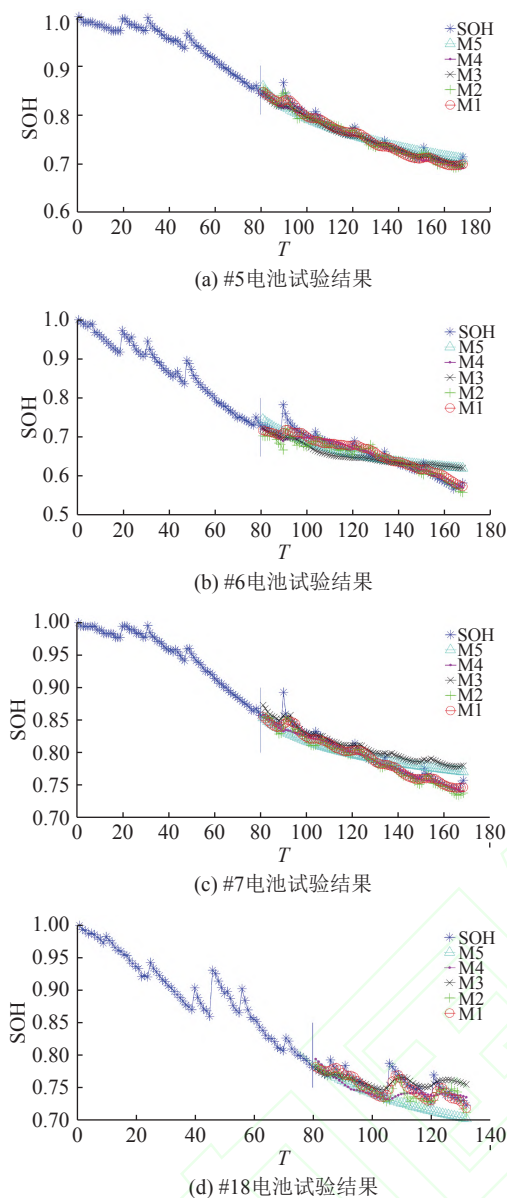


图 11 各个集成模型的一步预测结果

Fig.11 One-step prediction results of each integration model

列长度.

从预测趋势图和指标值对比(见图 11、12)可以看出,提出的方法是 5 组方案中预测性能最好的,基于 EEMD 和 CA 的多尺度分解使模型能够更有效地处理电池退化过程中的重生现象,针对主趋势和波动数据构建的 DBN 和 LSTM 集成模型提高了预测算法的准确性.图 12 给出 5 组实验评估指标的对比,本文方法的 RMSE、MAPE 和 MAE 指标都是最小的,即误差最小,预测精度最高,说明了本文预测方法的合理性和有效性.

为了进一步验证方法的优越性,将常用的预测模型 SVR、GPR 和 LR 与本文方法进行对比,包括姜媛媛等^[41]提出的 ELM 预测方法.图 13 中,

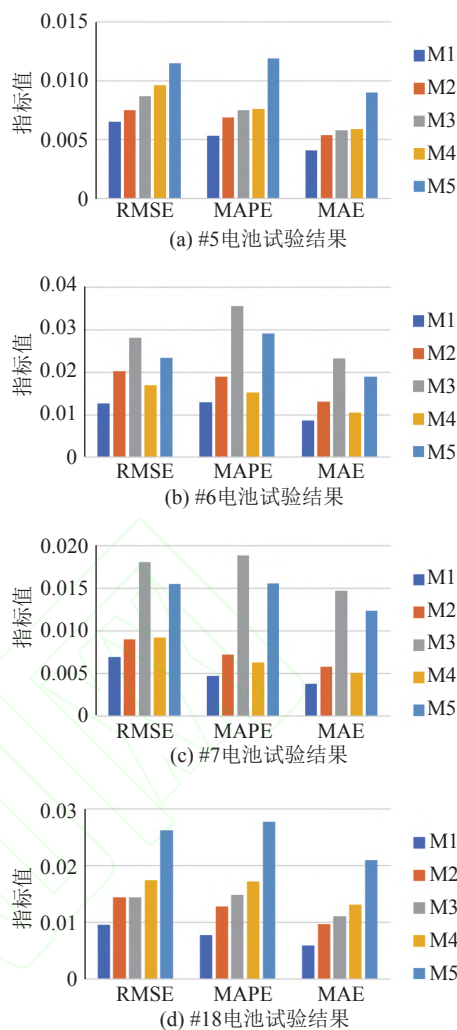


图 12 各个集成模型的一步预测指标值

Fig.12 Indicator values of each integration model for one-step prediction

M6、M7、M8 和 M9 分别为各方法的指标结果.通过指标值对比可以看出,提出的方法在各项指标中都是最优的,且指标值基本都小于 0.01.基于多尺度分解与深度网络的集成模型大大提高了预测方法的准确性和稳定性,与其他预测模型相比,表现出更优越的性能.

2.3 Multi-steps-ahead 预测

电池的 RUL 预测需要对长期预测范围内的健康退化进行准确的估计.对各组电池进行长期预测的试验,即多步预测(multi-steps prediction)来测试方法的性能,在该实验中将步长设定为 5.如图 14、15 所示分别为 5 组电池实验的预测结果.可以看出,提出的多尺度集成方法相比其他 4 种方法展现了更好的预测结果,具有更好的长期预测能力.将方法进行逐一对比可以发现,利用数据的多尺度分解与深度网络的集成模型能够显著




图 13 各个对比模型的一步预测指标值

Fig.13 Indicator values of each contrast model for one-step prediction

改善方法的预测效果.

在 five-steps-ahead 预测实验中, 与其他方法进行对比. 通过观察图 13、16 可以发现, 其他模型在进行长期预测时性能会大幅下降, 本文提出的集成模型具有更稳定的预测性能. 实验结果证明了该方法的有效性, 长期预测的准确性高于其他方法, 表明能够更好地预测电池未来的健康退化趋势.

2.4 剩余寿命预测

电池剩余寿命是在 SOH 超过预设失效阈值之前剩余的时间长度. 为了说明该方法的预测能力, 开展 2 组电池 (电池 #5 和 #6) 在不同预测时间点 (starting prediction point, SPP) 下的剩余寿命预测实验. 通过参考 NASA 实验数据标准, 当电池充电容量下降到 1.38 A·h 时视为寿命 (end of Life, EoL) 结束, 通过本文方法预测寿命结束时间 (end of prediction, EoP), 计算不同 SPP 下的预测误差 (prediction errors, PE).




图 14 各个集成模型的 5 步预测结果

Fig.14 Five-step prediction results of each integration model

表 7、图 17 给出预测时间点 80、90 和 100 时的 RUL 预测结果, 在不同时间点预测采用相同的设置. SPP=80 时的 EoP 与实际 EoL 所存在的误差在早期预测中是可以接受的, 同时预测模型的输出与实际的电池容量退化趋势基本保持一致, 为早期预测提供了良好的依据. 随着预测时间点的往后推移, 预测准确度逐渐提高, 在中后期获得更精确的 RUL 预测结果, 能够实时地反馈电池未来的健康状况, 以便在相应时期进行合理的维护, 确保整个系统能够持续、高效地运行.

预测算法的不确定度是评估算法性能的重要指标, 算法的不确定度在 RUL 预测中主要体现在失效阈值或预测结果的不确定性^[42]. 本文中的失




图 15 各个集成模型的 5 步预测指标值

Fig.15 Indicator values of each integration model for five-step prediction

效阈值是给定的,而在数据处理以及模型构建阶段的不确定性可能会影响预测结果.开展多组重复实验,对预测算法的不确定性进行量化分析,验证方法的稳定性.以#5 电池为例,图 18 给出 100 组 SPP 为 100 时的 RUL 预测结果.图中, f 为 EoP 的频数.该实验中的大部分预测结果集中在 EoL(129)附近,所有 EoP 均为 125~134,绝对值误差较小,证明算法具有稳定的预测性能,能够有效地应对不确定性因素的影响,体现出良好的自适应性.

3 结 语

本文提出基于多尺度分解和深度神经网络的锂电池健康预测模型,对锂电池的健康趋势变化进行有效的学习与预测集成.本文采用锂电池容量作为健康指标,通过 EEMD 和相关性分析对数

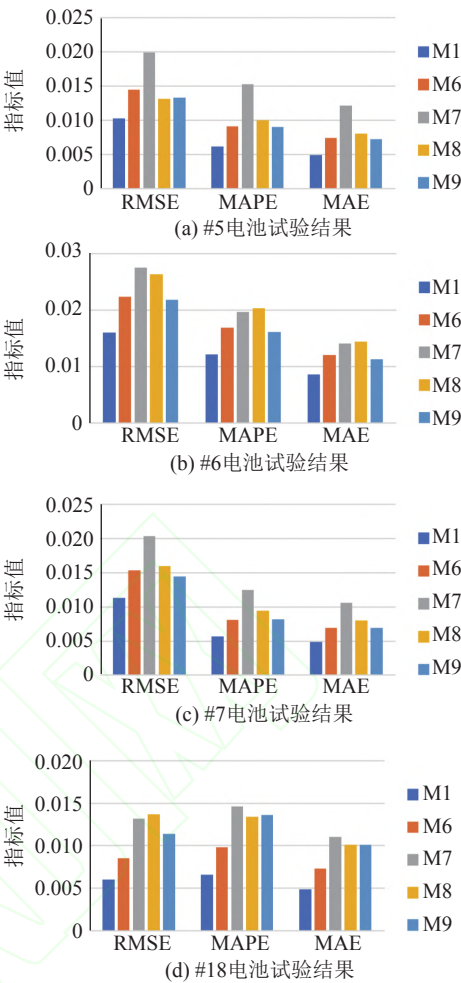


图 16 各个对比模型的 5 步预测指标值

Fig.16 Indicator values of each contrast model for five-step prediction

据进行预处理,将数据分为主趋势数据和波动数据,显著提高了该模型的预测准确性.基于深度学习优异的特征学习能力,DBN 和 LSTM 分别建模电池能量变化的全局趋势与波动,将各模型输出进行集成,得到最终的 RUL 预测结果.实验结果验证了基于多尺度分解和深度神经网络的锂电池健康预测的有效性与优越性.

表 7 剩余使用寿命的预测结果

Tab.7 RUL prediction results of remaining useful life

电池编号	SPP	EoL	EoP	PE
#5	80	129	145	16
#5	90	129	121	8
#5	100	129	128	1
#6	80	113	108	13
#6	90	113	106	10
#6	100	113	99	8




图 17 剩余使用寿命的预测结果

Fig.17 Prediction results of remaining useful life




图 18 不确定性分析的实验结果

Fig.18 Experimental results of uncertainty analysis

参考文献 (References):

- [1] GOEBEL K, SAHA B, SAXENA A, et al. Prognostics in battery health management [J]. **IEEE Instrumentation and Measurement Magazine**, 2008, 11(4): 33-40.
- [2] OLIVARES B E, CERDA M, MATIAS A, et al. Particle-filtering-based prognosis framework for energy storage devices with a statistical characterization of state-of-health regeneration phenomena [J]. **IEEE Transactions on Instrumentation and Measurement**, 2013, 62(2): 364-376.
- [3] YU J. Local and nonlocal preserving projection for bearing defect classification and performance assessment [J]. **IEEE Transactions on Industrial Electronics**, 2012, 59(5): 2363-2376.
- [4] KIM I S. A Technique for estimating the state of health of lithium batteries through a dual-sliding-mode observer [J]. **IEEE Transactions on Power Electronics**, 2010, 25(4): 1013-1022.
- [5] LIU D, XIE W, LIAO H, et al. Integrated prognostic framework with probability ensemble for lithium-ion battery [J]. **IEEE Transactions on Instrumentation and Measurement**, 2015, 64(3): 660-670.
- [6] 张洋, 陈浩, 郭波, 等. 锂离子电池剩余寿命在线预测 [J]. **机械科学与技术**, 2016, 35(8): 1286-1290.
ZHANG Yang, CHEN Hao, GUO Bo, et al. Online prediction of remaining useful lifetime for lithium-ion batteries [J]. **Mechanical Science and Technology for Aerospace Engineering**, 2016, 35(8): 1286-1290.
- [7] 王常虹, 董汉成, 凌明祥, 等. 车用锂离子电池剩余使用寿命预测方法 [J]. **汽车工程**, 2015, 37(4): 476-479.
WANG Chang-hong, DONG Han-cheng, LING Ming-xiang, et al. Remaining useful life prediction of automotive lithium-ion battery [J]. **Automotive Engineering**, 2015, 37(4): 476-479.
- [8] ASHWIN T R, CHUNG Y M, WANG J. Capacity fade modelling of lithium-ion battery under cyclic loading conditions [J]. **Journal of Power Sources**, 2016, 328: 586-598.
- [9] XING Y J, MA E W M, TSUI K L, et al. An ensemble model for predicting the remaining useful performance of lithium-ion batteries [J]. **Microelectronics Reliability**, 2013, 53(6): 811-820.
- [10] LYU C, LAI Q, GE T, et al. A lead-acid battery's remaining useful life prediction by using electrochemical model in the particle filtering framework [J]. **Energy**, 2017, 120: 975-984.
- [11] LI D, WANG W, ISMAIL F. A mutated particle filter technique for system state estimation and battery life prediction [J]. **IEEE Transactions on Instrumentation and Measurement**, 2014, 63(8): 2034-2043.
- [12] LEE S, KIM J, LEE J, et al. State-of-charge and capacity estimation of lithium-ion battery using a new open-circuit voltage versus state-of-charge [J]. **Journal of Power Sources**, 2008, 185(2): 1367-1373.
- [13] 李赛, 庞晓琼, 林慧龙, 等. 基于相关向量机的锂离子电池剩余寿命预测 [J]. **计算机工程与设计**, 2018, 39(8): 2682-2686.
LI Sai, PANG Xiao-qiong, LIN Hui-long, et al. RUL prediction for lithium-ion batteries based on relevance vector machine [J]. **Computer Engineering and Design**, 2018, 39(8): 2682-2686.
- [14] 王春雷, 赵琦, 秦孝丽, 等. 基于改进相关向量机的锂电池寿命预测方法 [J]. **北京航空航天大学学报**, 2018,

- 44(9): 1998–2003.
- WANG Chun-lei, ZHAO Qi, QIN Xiao-li, et al. Research on improved relevance vector machine life prediction method of lithium battery [J]. **Journal of Beijing University of Aeronautics and Astronautics**, 2018, 44(9): 1998–2003.
- [15] HU C, JAIN G, SCHMIDT C, et al. Online estimation of lithium-ion battery capacity using sparse Bayesian learning [J]. **Journal of Power Sources**, 2015, 289: 105–113.
- [16] ZHANG Y, GUO B. Online capacity estimation of lithium-ion batteries based on novel feature extraction and adaptive multi-kernel relevance vector machine [J]. **Energies**, 2015, 8(11): 12439–12457.
- [17] WANG S, ZHAO L L, SU X H, et al. Prognostics of lithium-ion batteries based on battery performance analysis and flexible support vector regression [J]. **Energies**, 2014, 7(10): 6492–6508.
- [18] 陈雄姿, 于劲松, 唐荻音, 等. 基于贝叶斯 LS-SVR 的锂电池剩余寿命概率性预测 [J]. **航空学报**, 2013, 34(9): 2219–2229.
- CHEN Xiong-zi, YU Jin-song, TANG Di-yin, et al. Probabilistic residual life prediction for lithium-ion batteries based on Bayesian LS-SVR [J]. **Acta Aeronautica ET Astronautica Sinica**, 2013, 34(9): 2219–2229.
- [19] 庞景月, 马云彤, 刘大同, 等. 锂离子电池剩余寿命间接预测方法 [J]. **中国科技论**, 2014, 9(1): 28–36.
- PANG Jing-yue, MA Yun-tong, LIU Da-tong, et al. Indirect remaining useful life prognostics for lithium-ion battery [J]. **China Sciencepaper**, 2014, 9(1): 28–36.
- [20] EDDAHECH A, BRIAT O, BERTRAND J, et al. Behavior and state-of-health monitoring of lithium-ion batteries using impedance spectroscopy and recurring neural networks [J]. **International Journal of Electrical Power and Energy**, 2012, 42(1): 487–494.
- [21] XING Y, MA E W M, TSUI K L, et al. An ensemble model for predicting the remaining useful performance of lithium-ion batteries [J]. **Microelectronics Reliability**, 2013, 53: 811–820.
- [22] LI H, PAN D, CHEN C L P. Intelligent prognostics for battery health monitoring using the mean entropy and relevance vector machine [J]. **IEEE Transactions on Systems Man and Cybernetics Systems**, 2014, 44(7): 851–862.
- [23] SAHA B, GOEBEL K, POLL S, et al. Prognostics methods for battery health monitoring using a Bayesian framework [J]. **IEEE Transactions on Instrumentation and Measurement**, 2009, 58(2): 291–296.
- [24] DONG H, JIN X, LOU Y, et al. Lithium-ion battery state of health monitoring and remaining useful life prediction based on support vector regression-particle filter [J]. **Journal of Power Sources**, 2014, 271: 114–123.
- [25] YU J B. State of health prediction of lithium-ion batteries: multiscale logic regression and gaussian process regression ensemble [J]. **Reliability Engineering and System Safety**, 2018, 174: 82–95.
- [26] 沈延斌, 陈岭, 郭浩东, 等. 基于深度学习的放置方式和位置无关运动识别 [J]. **浙江大学学报: 工学版**, 2016, 50(6): 1141–1148.
- SHEN Yan-bin, CHEN Ling, GUO Hao-dong, et al. Deep learning based activity recognition independent of device orientation and placement [J]. **Journal of Zhejiang University: Engineering Science**, 2016, 50(6): 1141–1148.
- [27] NAIR V, HINTON G E. 3-D object recognition with deep belief nets [C] // **Advances in Neural Information Processing Systems 22: 23rd Annual Conference on Neural Information Processing Systems**. Vancouver: Curran Associates Inc, 2012: 1527–1554.
- [28] BAKER J, DENG L, GLASS J. Developments and directions in speech recognition and understanding [J]. **IEEE Signal Processing Magazine**, 2009, 26(3): 75–80.
- [29] TAMILSELVAN P, WANG P. Failure diagnosis using deep belief learning based health state classification [J]. **Reliability Engineering and System Safety**, 2013, 115: 124–135.
- [30] SHAO H, JIANG H, ZHANG X, et al. Rolling bearing fault diagnosis using an optimization deep belief network [J]. **Measurement Science and Technology**, 2015, 26(11): 1–17.
- [31] 袁公萍, 汤一平, 韩旺明, 等. 基于深度卷积神经网络的车型识别方法 [J]. **浙江大学学报: 工学版**, 2018, 52(4): 694–702.
- YUAN Gong-ping, TANG Yi-ping, HAN Wang-ming, et al. Vehicle category recognition based on deep convolutional neural network [J]. **Journal of Zhejiang University: Engineering Science**, 2018, 52(4): 694–702.

- [32] 陶洁, 刘义伦, 付卓, 等. 基于Teager能量算子和深度置信网络的滚动轴承故障诊断[J]. 中南大学学报: 自然科学版, 2017, 48(1): 61-68.
TAO Jie, LIU Yi-lun, FU Zhuo, et al. Fault damage degrees diagnosis for rolling bearing based on Teager energy operator and deep belief network [J]. **Journal of Central South University: Science and Technology**, 2017, 48(1): 61-68.
- [33] MA X, TAO Z, WANG Y, et al. Long short-term memory neural network for traffic speed prediction using remote microwave sensor data [J]. **Transportation Research Part C: Emerging Technologies**, 2015, 54: 187-197.
- [34] KUREMOTO T, KIMURA S, KOBAYASHI K, et al. Time series forecasting using a deep belief network with restricted Boltzmann machines [J]. **Neurocomputing**, 2014, 137(15): 47-56.
- [35] WU Y, YUAN M, DONG S, et al. Remaining useful life estimation of engineered systems using vanilla LSTM neural networks [J]. **Neurocomputing**, 2017, 275: 16-179.
- [36] ZHANG C, LIM P, QIN A K, et al. Multi-objective deep belief networks ensemble for remaining useful life estimation in prognostics [J]. **IEEE Transactions on Neural Networks and Learning Systems**, 2017, 28(10): 2306-2318.
- [37] HUANG N E, SHEN Z, LONG S R, et al. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis [J]. **Proceedings A**, 1998, 454(1971): 903-995.
- [38] 熊旸, 杨世锡, 周晓峰. 旋转机械振动信号的固有模式函数降噪方法 [J]. 浙江大学学报: 工学版, 2011, 45(8): 1376-1381.
XIONG Xin, YANG Shi-xi, ZHOU Xiao-feng. IMF-based denoising method for vibration signal in rotating machinery [J]. **Journal of Zhejiang University: Engineering Science**, 2011, 45(8): 1376-1381.
- [39] WU Z, HUANG N E. Ensemble empirical mode decomposition: a noise-assisted data analysis method [J]. **Advances in Adaptive Data Analysis**, 2009, 1(1): 1-41.
- [40] SAHA B, GOEBEL K. "Battery Data Set", NASA Ames prognostics data repository [DB/OL]. [2016-05-12]. <http://ti.arc.nasa.gov/project/prognostic-data-repository/>.
- [41] 姜媛媛, 刘柱, 罗慧, 等. 锂电池剩余寿命的ELM间接预测方法 [J]. 电子测量与仪器学报, 2016, 30(2): 179-185.
JIANG Yuan-yuan, LIU Zhu, LUO Hui, et al. ELM indirect prediction method for the remaining life of lithium-ion battery [J]. **Journal of Electronic Measurement and Instrumentation**, 2016, 30(2): 179-185.
- [42] WANG P, YOUNG B D, HU C. A generic probabilistic framework for structural health prognostics and uncertainty management [J]. **Mechanical Systems and Signal Processing**, 2012, 28: 622-637.